

总复习

概率论与数理统计

概率论与数理统计

- 一. 随机事件与概率
 - 二. 随机变量与分布函数
 - 三. 多维随机变量及其分布
 - 四. 随机变量的数字特征
 - 五. 大数定律和中心极限定理
 - 六. 数理统计的基本概念
 - 七. 参数估计
 - 八. 假设检验
- 
- 概率论
- 数理统计

第一章 随机事件及其概率

1. 随机事件（基本概念，关系与运算）
2. 频率与概率（古典、几何、公理化定义，性质，计算）
3. 条件概率、全概率公式和贝叶斯公式（乘法公式、贝叶斯公式）
4. 事件的独立性（ $P(AB) = P(A)P(B)$ ，伯努利概型）
 - 简单应用—如何求概率

事件A发生的频率： $f_n(A) = \frac{n_A}{n}$ ，其中 n_A 是 n 次试验中事件A发生的次数（频数）

频率的性质：

1. $0 \leq f_n(A) \leq 1$
2. $f_n(\Omega) = 1$
3. 若A、B互斥，则 $f_n(A \cup B) = f_n(A) + f_n(B)$

古典概型 $P(A) = \frac{A \text{中包含的样本点数}}{\text{样本点总数}}$

几何概率 $P(A_g) = \frac{m(g)}{m(\Omega)}$

概率的公理化定义

设 E 是随机试验， Ω 是其样本空间，对于 E 中的每一个事件 A 赋予一实数，记为 $P(A)$ 。若它满足：

- 非负性 对每一个事件 A ，有 $0 \leq P(A) \leq 1$;
- 规范性 $P(\Omega) = 1$;
- 可列可加性 若 $A_i A_j = \emptyset, (i \neq j)$ ，有 $P(\bigcup_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$;

称 $P(A)$ 为事件 A 的概率。

概率的性质:

- 不可能事件概率为0, 即 $P(\emptyset) = 0$.
- 有限可加性.若 $A_i A_j = \emptyset, (i \neq j, i, j = 1, 2, \dots, n)$, 有 $P(\bigcup_{i=1}^n A_i) = \sum_{i=1}^n P(A_i)$.
- $P(\bar{A}) = 1 - P(A)$.
- 设A,B是两事件, 则 $P(A - B) = P(A) - P(AB)$.
- 若 $B \subset A$, 则 $P(A - B) = P(A) - P(B)$.
- 若 $B \subset A$, 则 $P(A) \geq P(B)$.
- $P(A \cup B) = P(A) + P(B) - P(AB)$.
- 一般加法公式
 - 推论1 (布尔不等式)
 $P(A \cup B) \leq P(A) + P(B)$.
 - 推论2 (Bonferroni不等式)
 $P(AB) \geq P(A) + P(B) - 1$.

$$P\left(\bigcup_{i=1}^n A_i\right) = \sum_{i=1}^n P(A_i) - \sum_{1 \leq i < j \leq n} P(A_i A_j) + \sum_{1 \leq i < j < k \leq n} P(A_i A_j A_k) - \dots + (-1)^{n-1} P(A_1 A_2 \dots A_n).$$

条件概率: $P(B|A) = \frac{P(AB)}{P(A)}$

乘法公式:

- $P(AB) = P(A)P(B|A) = P(B)P(A|B), P(B) > 0$
- $P(A_1A_2 \dots A_n) = P(A_1)P(A_2|A_1)P(A_3|A_1A_2) \dots P(A_n|A_1A_2 \dots A_{n-1}),$
 $P(A_1A_2 \dots A_{n-1}) > 0$

$$B = \sum_{i=1}^n A_i B$$

$$P(B) = \sum_{i=1}^n P(A_i)P(B|A_i) \quad \text{全概率公式}$$

先验概率

$$\frac{P(A_i|B)}{\quad} = \frac{P(A_i)P(B|A_i)}{\sum_{i=1}^n P(A_i)P(B|A_i)}$$

后验概率

贝叶斯公式
(后验概率公式)

条件概率的性质：

- 非负性 $0 \leq P(B|A) \leq 1;$
- 规范性 $P(\Omega|A) = 1;$
- 可列可加性 若 $B_i B_j = \emptyset, (i \neq j)$, 有 $P(\cup_{i=1}^{\infty} B_i|A) = \sum_{i=1}^{\infty} P(B_i|A);$
- $P(\emptyset|A) = 0.$
- $P(\bar{B}|A) = 1 - P(B|A).$
- $P(B \cup C|A) = P(B|A) + P(C|A) - P(BC|A).$

事件A与B相互独立: $P(AB) = P(A)P(B)$ 。

定理1 (相互独立的充要条件): $P(A) > 0$, 则事件A与B相互独立 $\Leftrightarrow P(B|A) = P(B)$.

定理2 以下四个命题等价

1. 事件A与B相互独立;
2. 事件A与 $\bar{B}$ 相互独立;
3. 事件 $\bar{A}$ 与B相互独立;
4. 事件 $\bar{A}$ 与 $\bar{B}$ 相互独立.

三个事件的独立性: 若以下四式同时成立, 称事件A,B,C是相互独立的。

$$(1) \begin{cases} P(AB) = P(A)P(B) \\ P(AC) = P(A)P(C) \\ P(BC) = P(B)P(C) \end{cases}$$

$$(2) P(ABC) = P(A)P(B)P(C)$$

n个事件的独立性: 对n个事件 $A_1, A_2, \dots, A_n$, 若对任意整数 $k (1 < k \leq n)$ 和任意k个整数 $i_1, i_2, \dots, i_k (1 \leq i_1 < i_2 < \dots < i_k \leq n)$ 都有 $P(A_{i_1} A_{i_2} \dots A_{i_k}) = P(A_{i_1}) P(A_{i_2}) \dots P(A_{i_k})$

所有等式的个数之和: $\sum_{k=2}^n C_n^k = \sum_{k=0}^n C_n^k - C_n^1 - C_n^0 = 2^n - n - 1$

伯努利试验:只有两个对立的结果A与 $\bar{A}$

n重伯努利试验(伯努利概型):伯努利试验在相同条件下重复进行n次,且各次试验是独立的)。样本点共 2^n 个。

伯努利概型中的一些分布

1. **伯努利分布**: $P(A) = p, P(\bar{A}) = 1 - p$. 只进行一次伯努利试验, 或者事件A出现, 或者事件 $\bar{A}$ 出现
2. **二项分布**: $P(X = k) = C_n^k p^k (1 - p)^{n-k}, k = 0, 1, 2, \dots, n$ n次试验中事件A出现k次
3. **几何分布**: $P(X = k) = (1 - p)^{k-1} p$ 事件A首次成功出现在第k次
4. **超几何分布**: $P(X = k) = \frac{C_M^k C_{N-M}^{n-k}}{C_N^n}$

第二章 随机变量与分布函数

1. 随机变量及其分布
2. 离散型随机变量及其分布
3. 连续性随机变量及其分布（均匀分布、指数分布、正态分布）
4. 随机变量的函数及其分布

第三章 多维随机变量及其分布

1. 多维随机变量及其联合分布（二维均匀分布、二维正态分布）
2. 边缘分布
- ~~3. 条件分布~~
4. 随机变量的独立性
5. 多维随机变量的函数的分布（和、商、~~积（连续型）~~、极值、顺序统计量）

设 Ω 是随机试验 E 对应的样本空间，若对于任意的 $\omega \in \Omega$ ，都有唯一的一个实数 $X(\omega)$ 与之对应，这样就定义了一个在 Ω 上的实值函数，称这个函数 $X(\omega)$ 为随机变量。

设随机事件 E 的样本空间 Ω ，对于 $\forall \omega \in \Omega$ ，都有确定的两个实数 $X_1(\omega), X_2(\omega)$ 与之对应，称有序二元总体 $X(\omega) = (X_1(\omega), X_2(\omega))$ 为一个二维随机向量（二维随机变量）。

若随机变量 $X_1(\omega), X_2(\omega), \dots, X_n(\omega)$ ，定义在同一个概率空间上，称 $X(\omega) = (X_1(\omega), X_2(\omega), \dots, X_n(\omega))$ 构成一个 n 维随机向量（ n 维随机变量）。

一维随机变量	{	离散型	分布律
		连续型	概率密度

二维随机变量	{	离散型	联合分布律
		连续型	联合概率密度

一维随机变量的分布函数:

$$F(x) = P\{X \leq x\}, x \in (-\infty, +\infty).$$

二维随机变量 (X_1, X_2) 的（联合）分布函数:

$$F(x_1, x_2) = P\{X_1(\omega) \leq x_1, X_2(\omega) \leq x_2\}$$

$$-\infty < x_i < +\infty$$

n维随机向量的（联合）分布函数:

$$F(x_1, x_2, \dots, x_n) = P\{X_1(\omega) \leq x_1, X_2(\omega) \leq x_2, \dots, X_n(\omega) \leq x_n\}$$

二维随机变量 (X, Y) 关于 X, Y 的边缘分布函数:

$$F_X(x) = P(X \leq x) = P(X \leq x, Y < +\infty) = F(x, +\infty)$$

$$F_Y(y) = P(Y \leq y) = P(X < +\infty, Y \leq y) = F(+\infty, y)$$

分布函数的性质

一维分布函数

- $0 \leq F(x) \leq 1, \forall x \in (-\infty, +\infty)$
- 单调性：关于变元单调不减
- 连续性：关于变元右连续
- 标准性： $F(-\infty) = 0, F(+\infty) = 1$
- $P\{a < X \leq b\} = F(b) - F(a)$
 $\forall a \leq b$

二维分布函数

- $0 \leq F(x_1, x_2) \leq 1, \forall x_1, x_2 \in (-\infty, +\infty)$
- 单调性：关于每个变元单调不减
- 连续性：关于每个变元右连续
- $F(-\infty, x_2) = 0, F(x_1, -\infty) = 0,$
 $F(-\infty, -\infty) = 0. F(+\infty, +\infty) = 1.$
 $F(+\infty, x_2) \neq 1, F(x_1, +\infty) \neq 1.$
- $P\{a_1 < X_1 \leq b_1, a_2 < X_2 \leq b_2\} =$
 $F(b_1, b_2) - F(a_1, b_2) - F(b_1, a_2) + F(a_1, a_2)$
 $\forall a_1 \leq b_1, a_2 \leq b_2$

X	x_1	x_2	...	x_i	...
P	$p(x_1)$	$p(x_2)$	...	$p(x_i)$	...

$$\begin{pmatrix} x_1 & x_2 & \dots & x_i & \dots \\ p(x_1) & p(x_2) & \dots & p(x_i) & \dots \end{pmatrix}$$

离散型随机变量的分布列
(分布律)

(1) $p(x_i) \geq 0, i = 1, 2, 3, \dots$

(2) $\sum_i p(x_i) = 1$

分布函数: $F(x) = P(X \leq x) = \sum_{x_i \leq x} p(x_i)$

(1) 退化分布

(2) 两点分布

(3) 二项分布

(4) 几何分布

(5) 超几何分布

(6) 泊松分布

二维离散型随机变量(X,Y),分布律 $P(X = x_i, Y = y_j) = p_{ij}, i, j = 1, 2, \dots,$

边缘分布律 $P(X = x_i) = \sum_j p_{ij} = p_{i\cdot}, P(Y = y_j) = \sum_i p_{ij} = p_{\cdot j}$

条件分布律 $P(Y = y_j | X = x_i) = \frac{p_{ij}}{p_{i\cdot}}, P(X = x_i | Y = y_j) = \frac{p_{ij}}{p_{\cdot j}}$

	y_1	y_2	...	y_j	...	$P(X = x_i)$
x_1	p_{11}	p_{12}	...	p_{1j}	...	$p_{1\cdot} = \sum_j p_{1j}$
x_2	p_{21}	p_{22}	...	p_{2j}	...	$p_{2\cdot} = \sum_j p_{2j}$
...	...	...	...	...	...	...
x_i	p_{i1}	p_{i2}	...	p_{ij}	...	$p_{i\cdot} = \sum_j p_{ij}$
...	...	...	...	...	...	...
$P(Y = y_i)$	$p_{\cdot 1} = \sum_i p_{i1}$	$p_{\cdot 2} = \sum_i p_{i2}$	...	$p_{\cdot j} = \sum_i p_{ij}$	...	1

- $p_{ij} \in [0,1]$
- $\sum_{i,j} p_{ij} = 1$
- $P(Y = y_j | X = x_i) \geq 0$
- $\sum_j P(Y = y_j | X = x_i) = 1$

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t)dt, x \in (-\infty, +\infty)$$

连续型随机变量的概率密度：非负实值可积函数 $f(x)$

概率密度函数 $f(x)$ 的性质：

$$(1) F'(x) = f(x)$$

$$(5) P(X \in S) = \int_S f(t)dt$$

$$(2) f(x) \geq 0, x \in (-\infty, +\infty)$$

$$(6) P(X = c) = 0$$

$$(3) \int_{-\infty}^{+\infty} f(x)dx = 1$$

$$(4) a < b \text{ 时, } F(b) - F(a) = P(a < X \leq b) = \int_a^b f(t)dt = P(a < X < b) = P(a \leq X < b)$$

(1) 均匀分布

(2) 指数分布

(3) 正态分布

(4) Γ 分布

(5) χ^2 分布

(6) 对数正态分布

设二维随机变量 (X, Y) 的分布函数为 $F(x, y)$, 若 $\exists$ 非负可积函数 $f(x, y)$, 对 $\forall$ 实数 x, y 都有 $F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv$, 称 (X, Y) 为二维连续型随机变量, $f(x, y)$ 为 (X, Y) 的概率密度函数 (概率密度), 或 X 和 Y 的联合概率密度。

- $f(x, y) \geq 0$
- $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(u, v) du dv = 1$
- 若 $f(x, y)$ 在 (x_0, y_0) 连续, 则 $\frac{\partial^2 F(x, y)}{\partial x \partial y} \big|_{(x_0, y_0)} = f(x_0, y_0)$
- $P\{(X, Y) \in D\} = \iint_D f(x, y) dx dy$

(1) 均匀分布

(2) 正态分布

二维连续型随机变量 (X, Y)

概率密度函数 $f(x, y)$, 分布函数 $F(x, y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) du dv$.

边缘分布函数:

$$F_X(x) = P(X \leq x) = P(X \leq x, Y < +\infty) = \int_{-\infty}^x \int_{-\infty}^{+\infty} f(u, v) dv du$$

$$F_Y(y) = P(Y \leq y) = P(X < +\infty, Y \leq y) = \int_{-\infty}^y \int_{-\infty}^{+\infty} f(u, v) du dv$$

边缘概率密度函数:

$$f_X(x) = \int_{-\infty}^{+\infty} f(x, v) dv, x \in (-\infty, +\infty)$$

$$f_Y(y) = \int_{-\infty}^{+\infty} f(u, y) du, y \in (-\infty, +\infty)$$

条件概率:

$$F_{Y|X}(y|x) = P(Y \leq y|X = x) = \int_{-\infty}^y \frac{f(x, v)}{f_X(x)} dv$$

$$F_{X|Y}(x|y) = P(X \leq x|Y = y) = \int_{-\infty}^x \frac{f(u, y)}{f_Y(y)} du$$

离散型随机变量 X 的分布律

X	x_1	x_2	...	x_i	...
P	$p(x_1)$	$p(x_2)$	...	$p(x_i)$	...

随机变量的函数 $Y=g(X)$ 的分布律

$Y=g(X)$	$g(x_1)$	$g(x_2)$	...	$g(x_i)$	...
P	$p(x_1)$	$p(x_2)$	...	$p(x_i)$	...

离散型随机变量 X, Y 的联合分布

XY	x_1y_1	x_1y_2	...	x_iy_j	...
P	p_{11}	p_{12}	...	p_{ij}	...

随机变量的函数 $Z=g(X,Y)$ 的分布律

$Z=g(X,Y)$	$g(x_1, y_1)$	$g(x_1, y_2)$	...	$g(x_i, y_j)$	...
P	p_{11}	p_{12}	...	p_{ij}	...

注意：
相等的
函数值，
合并其
概率

定理： 设随机变量 X 的概率密度函数为 $f(x), x \in (-\infty, +\infty)$,
函数 $y = g(x)$ 严格单调且反函数 $x = g^{-1}(y)$ 有连续导数，则 Y 的概率密度 $h(y)$ 为

$$h(y) = \begin{cases} f(g^{-1}(y)) |(g^{-1}(y))'| & y \in \Omega_Y \\ 0 & y \notin \Omega_Y \end{cases} \quad \Omega_Y \text{ 是 } Y = g(X) \text{ 的值域}$$

若 $y = g(x)$ 分段严格单调且在每个分段区间存在导数连续的反函数 $\{g_i^{-1}(y)\}_{i=1}^n$ ，
则 Y 的概率密度 $h(y)$ 为

$$h(y) = \begin{cases} \sum_{i=1}^n f(g_i^{-1}(y)) |(g_i^{-1}(y))'| & y \in \Omega_Y \\ 0 & y \notin \Omega_Y \end{cases}$$

定理：随机变量 $X \sim N(\mu, \sigma^2), Y = kX + b (k \neq 0)$ 则 $Y \sim N(k\mu + b, (k\sigma)^2)$

若 (X_1, X_2) 是二维随机向量，其联合分布密度函数为 $f(x_1, x_2)$ ，若 $Y = g(X_1, X_2)$ ，则 Y 的分布函数法为

$$F_Y(y) = P(Y \leq y) = P(g(X_1, X_2) \leq y) = \iint_{G_y} f(x_1, x_2) dx_1 dx_2$$
$$G_y = \{(x_1, x_2) | g(x_1, x_2) \leq y\}$$

对 $F_Y(y)$ 求导，可得 Y 的概率密度函数 $h(y) = F'_Y(y)$

若 $(X_1, X_2, \dots, X_n)$ 是 n 维随机向量，其联合分布密度函数为 $f(x_1, x_2, \dots, x_n)$ ，若 $Y = g(X_1, X_2, \dots, X_n)$ ，则 Y 的分布函数法为

$$F_Y(y) = P(Y \leq y) = P(g(X_1, X_2, \dots, X_n) \leq y)$$
$$= \iiint_{G_y} f(x_1, x_2, \dots, x_n) dx_1 dx_2 \dots dx_n$$
$$G_y = \{(x_1, x_2, \dots, x_n) | g(x_1, x_2, \dots, x_n) \leq y\}$$

对 $F_Y(y)$ 求导，可得 Y 的概率密度函数 $h(y) = F'_Y(y)$

和的分布: $Z = X + Y$

离散型:

若 X 和 Y 是相互独立的随机变量, 都取非负整数值, 其概率分布分别为 $\{a_k\}$ 和 $\{b_k\}$

$$\{Z = r\} = \sum_{i=0}^r \{X = i, Y = r - i\} \quad r = 0, 1, 2, \dots$$

利用独立性, $P\{Z = r\} = \sum_{i=0}^r P\{X = i, Y = r - i\} = \sum_{i=0}^r P\{X = i\}P\{Y = r - i\}$

$$= \sum_{i=0}^r a_i b_{r-i}$$

离散卷积公式

和的分布: $Z = X + Y$

连续型:

若 X 和 Y 的联合分布密度函数为 $f(x, y)$,

$$\begin{aligned} F_Z(z) &= P(Z \leq z) = P(X + Y \leq z) = \iint_{X+Y \leq z} f(x, y) dx dy \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{z-x} f(x, y) dy dx = \int_{-\infty}^{\infty} \int_{-\infty}^{z-y} f(x, y) dx dy \end{aligned}$$

若 X 和 Y 相互独立,

$$\begin{aligned} F_Z(z) &= \int_{-\infty}^{\infty} \int_{-\infty}^{z-x} f_X(x) f_Y(y) dy dx = \int_{-\infty}^{\infty} \int_{-\infty}^z f_X(x) f_Y(u-x) du dx \\ &= \int_{-\infty}^z \int_{-\infty}^{\infty} f_X(x) f_Y(z-x) dx du \end{aligned}$$

$$Z \text{ 的概率密度函数 } f_Z(z) = \int_{-\infty}^{\infty} f_X(x) f_Y(z-x) dx = \int_{-\infty}^{\infty} f_X(z-y) f_Y(y) dy$$

卷积公式

极值分布: $M = \max(X, Y); N = \min(X, Y)$

- 若 X 和 Y 的联合概率密度函数为 $f(x, y)$,
$$F_M(z) = P(M \leq z) = P(X \leq z, Y \leq z) = \int_{-\infty}^z \int_{-\infty}^z f(x, y) dx dy$$

$$F_N(z) = P(N \leq z) = 1 - P(X > z, Y > z) = 1 - \int_z^{+\infty} \int_z^{+\infty} f(x, y) dx dy$$

- 若 X 和 Y 相互独立,

$$F_M(z) = P(M \leq z) = P(X \leq z, Y \leq z) = P(X \leq z)P(Y \leq z) = F_X(x)F_Y(y)$$

$$F_N(z) = P(N \leq z) = 1 - P(X > z, Y > z) = 1 - [1 - F_X(x)][1 - F_Y(y)]$$

- 若 $X_1, X_2, \dots, X_n$ 相互独立, $M = \max(X_1, X_2, \dots, X_n), N = \min(X_1, X_2, \dots, X_n)$, 则

$$F_M(z) = P(M \leq z) = \prod_{i=1}^n F_i(z) \qquad F_N(z) = 1 - \prod_{i=1}^n [1 - F_i(z)]$$

关于顺序统计量的分布

- 若 $X_1, X_2, \dots, X_n$ i.i.d., 分布函数均为 $F(x)$,
现对 $X_1, X_2, \dots, X_n$ 重新排序, $X_1^* \leq X_2^* \leq \dots \leq X_n^*$

$$\begin{aligned} F_{X_n^*}(x) &= P(X_n^* \leq x) = P\{\max(X_1, X_2, \dots, X_n) \leq x\} \\ &= P\{X_1 \leq x, X_2 \leq x, \dots, X_n \leq x\} \\ &= P\{X_1 \leq x\}P\{X_2 \leq x\} \dots P\{X_n \leq x\} \\ &= [F(x)]^n \end{aligned}$$

$$\begin{aligned} F_{X_1^*}(x) &= P(X_1^* \leq x) = 1 - P(X_1^* > x) = P\{\min(X_1, X_2, \dots, X_n) > x\} \\ &= 1 - P\{X_1 > x, X_2 > x, \dots, X_n > x\} \\ &= 1 - P\{X_1 > x\}P\{X_2 > x\} \dots P\{X_n > x\} \\ &= 1 - [1 - F(x)]^n \end{aligned}$$

关于顺序统计量的分布

若 $X_1, X_2, \dots, X_n$ i.i.d., 分布函数为 $F(x)$, 现对 $X_1, X_2, \dots, X_n$ 重新排序, $X_1^* \leq X_2^* \leq \dots \leq X_n^*$

X_1^*, X_n^* 的联合分布: $F_{X_1^*, X_n^*}(x, y) = P(X_1^* \leq x, X_n^* \leq y)$

$$\begin{aligned} \text{若 } x \geq y, \text{ 则 } F_{X_1^*, X_n^*}(x, y) &= P(X_1^* \leq x, X_n^* \leq y) \\ &= P\{X_n^* \leq y\} = [F(y)]^n \end{aligned}$$

$$\begin{aligned} \text{若 } x < y, \text{ 则 } F_{X_1^*, X_n^*}(x, y) &= P(X_1^* \leq x, X_n^* \leq y) = P\{X_n^* \leq y\} - P(X_1^* > x, X_n^* \leq y) \\ &= [F(y)]^n - [F(y) - F(x)]^n \end{aligned}$$

联合概率密度函数:

$$f_{X_1^*, X_n^*}(x, y) = \begin{cases} 0 & x \geq y \\ n(n-1)[F(y) - F(x)]^{n-2} f(x) f(y) & x < y \end{cases}$$

关于顺序统计量的分布

若 $X_1, X_2, \dots, X_n$ i.i.d., 分布函数为 $F(x)$, 现对 $X_1, X_2, \dots, X_n$ 重新排序, $X_1^* \leq X_2^* \leq \dots \leq X_n^*$

求极差 $R = X_n^* - X_1^*$ 的分布密度函数 $f_R(z)$:

当 $x \leq 0$ 时, $f_R(x) = 0$; 若 $x > 0$, 则

$$\begin{aligned} F_R(z) &= P(R \leq z) = \iint_{y-x \leq z} f_{X_1^*, X_n^*}(x, y) dx dy = \int_{-\infty}^{\infty} \int_{-\infty}^{z+x} f_{X_1^*, X_n^*}(x, y) dy dx \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^z f_{X_1^*, X_n^*}(x, x+z) dz dx = \int_{-\infty}^z \int_{-\infty}^{\infty} f_{X_1^*, X_n^*}(x, x+z) dx dz \end{aligned}$$

$$\begin{aligned} f_R(z) &= \int_{-\infty}^{\infty} f_{X_1^*, X_n^*}(x, x+z) dx \\ &= n(n-1) \int_{-\infty}^{\infty} [F(x+z) - F(x)]^{n-2} f(x) f(x+z) dx \end{aligned}$$

X 和 Y 是两个随机变量，若对任意的实数 x, y 都有 $P(X \leq x, Y \leq y) = P(X \leq x)P(Y \leq y)$ ，即 $F(x, y) = F_X(x)F_Y(y)$ ，联合分布函数等于两个边际分布函数的乘积，称随机变量 X 和 Y 相互独立。

$X_1, X_2, \dots, X_n$ 是 n 个随机变量，若对任意的 $x_1, x_2, \dots, x_n$ 成立 $P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n) = P(X_1 \leq x_1)P(X_2 \leq x_2) \dots P(X_n \leq x_n)$ ，称随机变量 $X_1, X_2, \dots, X_n$ 是相互独立的。

在这种场合，由每个随机变量的边际分布函数可以唯一确定联合分布函数。

定理. 若 X 和 Y 是分别取值于 $\{x_i\}$ 和 $\{y_j\}$ 的离散型随机变量，则 X 和 Y 相互独立 $\Leftrightarrow$ 若对任意的 x_i 和 y_j 都有 $P(X = x_i, Y = y_j) = P(X = x_i)P(Y = y_j)$

定理. 若 X 和 Y 是连续型随机变量，则 X 和 Y 相互独立 $\Leftrightarrow$ 若对任意的 x 和 y 都有 $f(x, y) = f_X(x)f_Y(y)$

若随机变量 X 和 Y 相互独立，条件分布可化为无条件分布。
即，对任意的实数 x, y 有 $P(Y \leq y | X = x) = P(Y \leq y)$ 。

第四章 随机变量的数字特征

1. 数学期望
2. 方差
3. 协方差与相关系数
4. 矩与协方差矩阵

- 设离散型随机变量 X 的分布律为 $P(X = x_i) = p_i, i = 1, 2, \dots$, 若级数 $\sum_{i=1}^{\infty} x_i p_i$ 绝对收敛, 称 $EX = \sum_{i=1}^{\infty} x_i p_i$ 的值为 X 的**数学期望** (或期望、均值)。
- 设连续型随机变量 X 的概率密度函数为 $f(x)$, 若 $EX = \int_{-\infty}^{+\infty} x f(x) dx$ 绝对收敛, 称它的值为 X 的**数学期望** (或均值)。
- 随机变量 X , 若 $E[X - EX]^2$ 存在, 称 $DX = E[X - EX]^2 = E(X^2) - (EX)^2$ 为 X 的**方差**。 X 的**标准差**为 $\sigma(X) = \sqrt{DX}$ 。
- (X, Y) 二维随机变量, 若 $cov(X, Y) = E\{[X - EX][Y - EY]\} = E(XY) - EX \cdot EY$ 存在, 称其为 (X, Y) 的**协方差**。
- $DX \cdot DY \neq 0$ 时, (X, Y) 的**相关系数** (标准协方差): $\rho_{XY} = \frac{cov(X, Y)}{\sqrt{DX}\sqrt{DY}}$, 即标准化的随机变量 $\frac{X - EX}{\sqrt{DX}}$ 与 $\frac{Y - EY}{\sqrt{DY}}$ 的协方差。 $\rho_{XY} = 0$ 时, 称 X 与 Y **不相关**。
- X 是随机变量, 若 $E(X)^k$ 存在, 则称 $E(X)^k$ 为 X 的 k 阶**原点矩**; 若 $E|X|^k$ 存在, 则称 $E|X|^k$ 为 X 的 k 阶**绝对原点矩**; 若 $E(X - EX)^k$ 存在, 则称 $E(X - EX)^k$ 为 X 的 k 阶**中心矩**; 若 $E|X - EX|^k$ 存在, 则称 $E|X - EX|^k$ 为 X 的 k 阶**绝对中心矩**;
- (X, Y) 是二维随机变量, 若 $E(X^k Y^l)$ 存在, 则称 $E(X^k Y^l)$ 为 (X, Y) 的 $k+l$ 阶**混合原点矩**; 若 $E[(X - EX)^k (Y - EY)^l]$ 存在, 则称 $E[(X - EX)^k (Y - EY)^l]$ 为 (X, Y) 的 $k+l$ 阶**混合中心矩**。

随机变量 X 的函数 $Y = g(X)$

- 若 X 是离散型随机变量, 分布律为 $P(X = x_i) = p_i, i = 1, 2, \dots$, 若级数 $\sum_{i=1}^{\infty} |g(x_i)|p_i$ 收敛, 称 $\sum_{i=1}^{\infty} g(x_i)p_i$ 的值为 Y 的数学期望, 记为:

$$EY = \sum_{i=1}^{\infty} g(x_i)p_i.$$

- 若 X 是连续型随机变量, 概率密度函数为 $f(x)$, 若积分 $\int_{-\infty}^{+\infty} g(x)f(x)dx$ 绝对收敛, 称它的值为 Y 的数学期望, 记为:

$$EY = \int_{-\infty}^{+\infty} g(x)f(x)dx.$$

设 (X,Y) 是二维随机变量, $Z = g(X,Y)$ 是 X 和 Y 的函数

- 离散型: 联合分布律为 $P(X = x_i, Y = y_j) = p_{ij}, i, j = 1, 2, \dots$, 若级数 $\sum_{i,j} |g(x_i, y_j)| p_{ij}$ 收敛, 称 $\sum_{i,j} g(x_i, y_j) p_{ij}$ 的值为 Z 的数学期望, 记为:

$$EZ = \sum_{i,j} g(x_i, y_j) p_{ij}.$$

- 连续型: 联合概率密度函数为 $f(x,y)$, 若积分 $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x,y) f(x,y) dx dy$ 绝对收敛, 称它的值为 Z 的数学期望, 记为:

$$EZ = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} g(x,y) f(x,y) dx dy.$$

$$EX = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} x f(x,y) dx dy = \int_{-\infty}^{+\infty} x f_X(x,y) dy.$$

$$EY = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} y f(x,y) dx dy = \int_{-\infty}^{+\infty} y f_Y(x,y) dy.$$

数学期望的性质：

- 若 $a \leq X \leq b$, 则 $a \leq EX \leq b$. 特别地 $Ec = c$. 这里 a, b, c 都是常量。
- $E(aX + b) = aE(X) + b$. 这里 a, b 是常量。

- 线性性质：对任意的常数 $c_i, i = 1, 2, \dots, n$ 及 b , 有

$$E\left(\sum_{i=1}^n c_i X_i + b\right) = \sum_{i=1}^n c_i E(X_i) + b.$$

- 若 X, Y 相互独立, 则 $E(XY) = E(X)E(Y)$.
- 若 $X_1, X_2, \dots, X_n$ 相互独立, 则 $E(\prod_{i=1}^n X_i) = \prod_{i=1}^n E(X_i)$.

方差的性质:

- $Dc = 0$. 这里 c 是常量。反之, 若 $DX = 0$, 则存在常数 c 使 $P(X = c) = 1$
- $D(aX + b) = a^2 D(X)$. 这里 a, b 是常量。
- $$\begin{aligned} D(X_1 \pm X_2) &= D(X_1) + D(X_2) \pm 2E\{[X_1 - E(X_1)][X_2 - E(X_2)]\} \\ &= D(X_1) + D(X_2) \pm 2[E(X_1 X_2) - E(X_1)E(X_2)] \end{aligned}$$
- 若 X_1, X_2 相互独立, 则 $D(X_1 \pm X_2) = D(X_1) + D(X_2)$
若 $X_1, X_2, \dots, X_n$ 相互独立, 则 $D(X_1 \pm X_2 \pm \dots \pm X_n) = \sum_{i=1}^n D(X_i)$
- $DX = \min_c E(X - c)^2$, i. e. $E(X - c)^2 \geq DX$
- 若 $c \neq EX$, 则 $DX < E(X - c)^2$

协方差的性质:

- $cov(X, Y) = cov(Y, X)$
- $cov(aX, bY) = abcov(Y, X)$
- $cov(X + Y, Z) = cov(X, Z) + cov(Y, Z)$

$$cov(X, Y) = E\{[X - EX][Y - EY]\} = E(XY) - EX \cdot EY$$

$$cov(X, X) = E\{[X - EX][X - EX]\} = DX$$

$$\begin{aligned} D(X_1 \pm X_2) &= D(X_1) + D(X_2) \pm 2[E(X_1X_2) - E(X_1)E(X_2)] \\ &= D(X_1) + D(X_2) \pm 2cov(X_1, X_2) \end{aligned}$$

$$\begin{aligned} D(X_1 + X_2 + X_3) \\ &= D(X_1) + D(X_2) + D(X_3) + 2cov(X_1, X_2) + 2cov(X_1, X_3) + 2cov(X_2, X_3) \end{aligned}$$

$$D(X_1 + X_2 + \cdots X_n) = \sum_{i=1}^n D(X_i) + 2 \sum_{1 \leq i < j \leq n} cov(X_i, X_j)$$

定理（柯西-施瓦兹不等式）：对任意的随机变量 X, Y ，有 $|EXY|^2 \leq EX^2 \cdot EY^2$
等号成立当且仅当 $P(Y = cX) = 1$ ，这里的 c 是一个常量。

定理： $|\rho_{XY}| \leq 1$, $\rho_{XY} = 1$ 当且仅当 $P\left(\frac{X-EX}{\sqrt{DX}} = \frac{Y-EY}{\sqrt{DY}}\right) = 1$;
 $\rho_{XY} = -1$ 当且仅当 $P\left(\frac{X-EX}{\sqrt{DX}} = -\frac{Y-EY}{\sqrt{DY}}\right) = 1$.

$\rho_{XY} = \pm 1$ 时，
 X 与 Y 存在线性关系

定理：对随机变量 X 和 Y ，下述4个等价：

- (1) X 与 Y 不相关；
- (2) $cov(X, Y) = 0$;
- (3) $E(XY) = EXEY$;
- (4) $D(X + Y) = DX + DY$;

定理：若随机变量 X 和 Y 相互独立，则 X 和 Y 不相关。

说明：独立性可以推出不相关，反过来不一定成立。

分布	概率分布	期望	方差	近似	其他
退化分布	$P(X = C) = 1$	C	0		
两点分布 $B(1, p)$	$P(X = k) = p^k (1 - p)^{1-k}$ $k = 0, 1$ 一次试验中事件A出现的次数	p	$p - p^2$		
二项分布 $B(n, p)$	$P(X = k) = C_n^k p^k (1 - p)^{n-k}$ $k = 0, 1, 2, \dots, n$ n重伯努利试验中事件A出现k次	np	$np(1 - p)$	n很大p很小时，可用泊松近似 $\frac{(np)^k}{k!} e^{-(np)}$	
几何分布 $G(p)$	$P(X = k) = (1 - p)^{k-1} p$ $k = 1, 2, \dots,$ n重伯努利试验中事件A首次出现在第k次	$\frac{1}{p}$	$\frac{1 - p}{p^2}$		无记忆性
超几何分布	$P(X = k) = \frac{C_M^k C_{N-M}^{n-k}}{C_N^n}$ $k = 0, 1, 2, \dots, \min(n, M)$ N件产品中次品M件，随机不放回抽n件出现次品数k	$\frac{nM}{N}$	$\frac{nM}{N} (1 - \frac{M}{N}) (\frac{N - n}{N - 1})$	N很大n很小时，可用二项分布近似 $C_n^k (\frac{M}{N})^k (1 - \frac{M}{N})^{n-k}$	
巴斯卡分布	$f(k, r, p) = C_{k-1}^{r-1} (1 - p)^{k-r} p^r$ $k = r, r + 1, \dots$ n重伯努利试验中事件A第r次出现在第k次试验	$\frac{r}{p}$	$\frac{r(1 - p)}{p^2}$		
泊松分布 $P(\lambda)$	$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}$ $k = 0, 1, 2, \dots, \lambda > 0$	λ	λ		

二项分布 $X_i \sim B(n, p_i), i = 1, 2, \dots, m$

$$X_i + X_j \sim B(n, p_i + p_j)$$

$$\text{cov}(X_i, X_j) = \{ D(X_i + X_j) - D(X_i) - D(X_j) \} / 2 = -np_i p_j$$

$$\rho_{X_i X_j} = \frac{\text{cov}(X_i, X_j)}{\sqrt{DX_i} \sqrt{DX_j}} = \frac{-np_i p_j}{\sqrt{np_i(1-p_i)} \sqrt{np_j(1-p_j)}} = -\sqrt{\frac{p_i p_j}{(1-p_i)(1-p_j)}}$$

二项分布：每次试验可能出现A或者不出现， $P(A) = p$, n次试验中A出现的次数X, 则 $P(X = k) = C_n^k p^k (1 - p)^{n-k}, k = 0, 1, 2, \dots, n$

多项分布：若每次试验可能出现的结果为 $A_1, A_2, \dots, A_r$, 而 $P(A_i) = p_i, \sum_i p_i = 1$. 试验相互独立，重复n次试验， A_i 出现的次数记为 X_i , 则

$$P(X_1 = k_1, X_2 = k_2, \dots, X_r = k_r) = \frac{n!}{k_1! k_2! \dots k_r!} p_1^{k_1} p_2^{k_2} \dots p_r^{k_r}$$

其中 $k_i \geq 0$ 且 $\sum_i k_i = n$. 否则概率为0.

超几何分布：对某批N件产品进行不放回抽样检查，这批产品中有M件次品，从中随机抽n件，x为出现的次品数， $P(X = k) = \frac{C_M^k C_{N-M}^{n-k}}{C_N^n}$.

多元超几何分布：袋中装i号球 N_i 只， $i = 1, 2, \dots, r, \sum_i N_i = N$. 现从中随机摸出n只，i号球出现数记为 X_i , 则

$$P(X_1 = n_1, X_2 = n_2, \dots, X_r = n_r) = \frac{C_{N_1}^{n_1} C_{N_2}^{n_2} \dots C_{N_r}^{n_r}}{C_N^n}$$

其中 $n_i \geq 0$ 且 $\sum_i n_i = n$. 否则概率为0.

分布	概率密度	分布函数	其他
均匀分布 $U(a, b)$ $a < b$	$f(x) = \begin{cases} \frac{1}{b-a}, & x \in (a, b) \\ 0, & x \notin (a, b) \end{cases}$	$F(x) = \begin{cases} 1, & x \in [b, +\infty) \\ \frac{x-a}{b-a}, & x \in [a, b) \\ 0, & x \in (-\infty, a) \end{cases}$	
指数分布 $E(\lambda)$ $\lambda > 0$	$f(x) = \begin{cases} 0, & x < 0 \\ \lambda e^{-\lambda x}, & x \geq 0 \end{cases}$	$F(x) = \begin{cases} 0, & x < 0 \\ 1 - e^{-\lambda x}, & x \geq 0 \end{cases}$	无记忆性 $\forall s, t > 0$, $P(X > t) =$ $P(X > s + t X > s)$
正态分布 $N(\mu, \sigma^2)$	$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, x \in (-\infty, +\infty)$	$F(x) = \Phi\left(\frac{x-\mu}{\sigma}\right) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^x e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt,$ $x \in (-\infty, +\infty)$	
Γ 分布 $\Gamma(\alpha, \beta)$ $\alpha, \beta > 0$	$f(x) = \begin{cases} 0, & x \leq 0 \\ \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, & x > 0 \end{cases}$		$\Gamma\left(\frac{n}{2}, \frac{1}{2}\right) = \chi^2(n)$
χ^2 分布 $\chi^2(n)$	$f(x) = \begin{cases} 0, & x \leq 0 \\ \frac{1}{2^{\frac{n}{2}}\Gamma(\frac{n}{2})} x^{\frac{n}{2}-1} e^{-\frac{x}{2}}, & x > 0 \end{cases}$		
对数正态分布 $LN(\mu, \sigma^2)$	$f(x) = \begin{cases} \frac{1}{\sqrt{2\pi}\sigma x} e^{-\frac{(\ln x - \mu)^2}{2\sigma^2}}, & x > 0 \\ 0, & otherwise \end{cases}$		

分布	概率密度	期望	方差	其他
均匀分布 $U(a, b)$ $a < b$	$f(x) = \begin{cases} \frac{1}{b-a}, & x \in (a, b) \\ 0, & x \notin (a, b) \end{cases}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	
指数分布 $E(\lambda)$ $\lambda > 0$	$f(x) = \begin{cases} 0, & x < 0 \\ \lambda e^{-\lambda x}, & x \geq 0 \end{cases}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$	无记忆性 $\forall s, t > 0,$ $P(X > t) = P(X > s + t X > s)$
正态分布 $N(\mu, \sigma^2)$	$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, x \in (-\infty, +\infty)$	μ	σ^2	
Γ 分布 $\Gamma(\alpha, \beta)$ $\alpha, \beta > 0$	$f(x) = \begin{cases} 0, & x \leq 0 \\ \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, & x > 0 \end{cases}$	$\frac{\alpha}{\beta}$	$\frac{\alpha}{\beta^2}$	$\Gamma\left(\frac{n}{2}, \frac{1}{2}\right) = \chi^2(n)$
χ^2 分布 $\chi^2(n)$	$f(x) = \begin{cases} 0, & x \leq 0 \\ \frac{1}{2^{\frac{n}{2}}\Gamma(\frac{n}{2})} x^{\frac{n}{2}-1} e^{-\frac{x}{2}}, & x > 0 \end{cases}$	n	$2n$	
对数正态分布 $LN(\mu, \sigma^2)$	$f(x) = \begin{cases} \frac{1}{\sqrt{2\pi}\sigma x} e^{-\frac{(\ln x - \mu)^2}{2\sigma^2}}, & x > 0 \\ 0, & otherwise \end{cases}$	$e^{\mu + \frac{\sigma^2}{2}}$	$(e^{\sigma^2} - 1)e^{2\mu + \sigma^2}$	

正态分布 $X \sim N(\mu, \sigma^2)$

$$\text{概率密度 } f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, x \in (-\infty, +\infty)$$

$$\text{分布函数 } F(x) = \Phi\left(\frac{x-\mu}{\sigma}\right) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^x e^{-\frac{(t-\mu)^2}{2\sigma^2}} dt, x \in (-\infty, +\infty)$$

标准正态分布 $X \sim N(0,1)$

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, x \in (-\infty, +\infty)$$

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt, x \in (-\infty, +\infty)$$

$$\text{分位点 } u_\alpha (\alpha \in (0,1)): P(X > u_\alpha) = \frac{1}{\sqrt{2\pi}} \int_{u_\alpha}^{+\infty} e^{-\frac{t^2}{2}} dt = \alpha$$

$$\text{期望 } EX = \int_{-\infty}^{+\infty} xf(x)dx = \mu$$

$$\text{方差 } DX = E[X - EX]^2 = \sigma^2$$

- 对称性：关于 $x = \mu$ 对称。
- 固定 σ ，改变 μ 的值不影响曲线形状。
- 最大值： $(\mu, \frac{1}{\sqrt{2\pi}\sigma})$
- σ 越大，曲线越平坦，峰顶越低；
 σ 越小，曲线越陡峭，峰顶越高。
- 渐近线： x 轴
- 拐点： $(\mu \pm \sigma, \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}})$

二元正态分布 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 概率密度:

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \exp\left\{-\frac{1}{2(1-\rho^2)} \left[\frac{(x-\mu_1)^2}{\sigma_1^2} - 2\rho\frac{(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \frac{(y-\mu_2)^2}{\sigma_2^2}\right]\right\}$$
$$x, y \in (-\infty, +\infty), \sigma_1 > 0, \sigma_2 > 0, |\rho| < 1$$

边缘密度 $f_X(x) = \int_{-\infty}^{+\infty} f(x, v) dv \sim N(\mu_1, \sigma_1^2)$, $f_Y(y) = \int_{-\infty}^{+\infty} f(u, y) du \sim N(\mu_2, \sigma_2^2)$

条件密度 $f(y|x) = \frac{f(x, y)}{f_X(x)} \sim N(\mu_2 + \rho \frac{\sigma_2}{\sigma_1}(x - \mu_1), (1 - \rho^2)\sigma_2^2)$

$$\rho_{XY} = \frac{\text{cov}(X, Y)}{\sqrt{DX}\sqrt{DY}} = \frac{E\{[X - \mu_1][Y - \mu_2]\}}{\sigma_1\sigma_2} = \frac{\rho\sigma_1\sigma_2}{\sigma_1\sigma_2} = \rho$$

定理. 二元正态分布 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, X 与 Y 独立的充要条件是 $\rho = 0$

对于二元正态分布, 独立性与不相关性是等价的。



$X \sim N(0, \sigma^2)$, k 阶原点矩 $E(X)^k = \begin{cases} 0, & k \text{ 为奇} \\ \sigma^k(k-1)(k-3) \dots 3 \cdot 1, & k \text{ 为偶} \end{cases}$ 特别地, $k=4$, $E(X)^4 = 3\sigma^4$

均匀分布

随机变量 X 的概率密度为: $f(x) = \begin{cases} \frac{1}{b-a}, & x \in (a, b) \\ 0, & x \notin (a, b) \end{cases}$

称 X 服从 (a, b) 上的均匀分布, $X \sim U(a, b)$

分布函数: $F(x) = \begin{cases} 1, & x \in [b, +\infty) \\ \frac{x-a}{b-a}, & x \in [a, b) \\ 0, & x \in (-\infty, a) \end{cases}$



二维均匀分布

若 G 为 $\mathbb{R}^2$ 中的有限区域, 且测度 $m(G) > 0$, 概率密度函数:

$$f(x, y) = \begin{cases} \frac{1}{m(G)}, & (x, y) \in G \\ 0, & (x, y) \notin G \end{cases}$$

随机变量 X 的分布函数 $F(x)$ 严格单增且连续, 则
 $Y = F(X)$ 服从 $[0, 1]$ 上的均匀分布。

第五章 大数定律与中心极限定理

1. 大数定律（重点：Chebyshev不等式）
2. 中心极限定理

定义（**独立同分布**）：若对于 $\forall n \geq 1, X_1, X_2, \dots, X_n$ 相互独立，则称随机变量序列 $X_1, X_2, \dots, X_n, \dots$ 是相互独立的；若还满足所有的 X_i 都有共同的分布，则称 $X_1, X_2, \dots, X_n, \dots$ 是独立同分布的随机变量序列。

定义（**依概率收敛**）：随机变量序列 $\{X_n\}$ ，若存在随机变量 X ，对 $\forall \varepsilon > 0$ 有 $\lim_{n \rightarrow \infty} P\{|X_n - X| \geq \varepsilon\} = 0$ 或者 $\lim_{n \rightarrow \infty} P\{|X_n - X| < \varepsilon\} = 1$ ，则称随机变量序列 $\{X_n\}$ 依概率收敛于随机变量 X ，记为： $X_n \xrightarrow{P} X$

定义（**大数定律**）：随机变量序列 $\{X_n\}$ ，且存在常数序列 $\{a_n\}$ ，令 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ ，若对 $\forall \varepsilon > 0$ 有 $\lim_{n \rightarrow \infty} P\{|\bar{X}_n - a_n| \geq \varepsilon\} = 0$ ，则称随机变量序列 $\{X_n\}$ 服从大数定律。一般的， a_n 取为 $E\bar{X}_n$ 。

定义（**中心极限定理**）：如果独立的随机变量序列 $\{X_n\}$ 的标准化和 $Y_n = \frac{\sum_{i=1}^n X_i - \sum_{i=1}^n EX_i}{\sqrt{\sum_{i=1}^n DX_i}}$ 使得下式成立， $\lim_{n \rightarrow \infty} P(Y_n \leq x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt$ ，称随机变量序列 $\{X_n\}$ 服从中心极限定理。

$$X_n \xrightarrow{P} X: \lim_{n \rightarrow \infty} P\{|X_n - X| \geq \varepsilon\} = 0 \quad (\forall \varepsilon > 0)$$

性质: 1. $X_n \xrightarrow{P} X \Rightarrow X_n - X \xrightarrow{P} 0;$

2. $X_n \xrightarrow{P} X, X_n \xrightarrow{P} Y \Rightarrow P(X = Y) = 1;$

3. $X_n \xrightarrow{P} X \Rightarrow X_n - X_m \xrightarrow{P} 0 (n, m \rightarrow \infty);$

4. $X_n \xrightarrow{P} X, Y_n \xrightarrow{P} Y \Rightarrow X_n \pm Y_n \xrightarrow{P} X \pm Y;$

5. $X_n \xrightarrow{P} X, k \text{ 为常数} \Rightarrow kX_n \xrightarrow{P} kX;$

6. $X_n \xrightarrow{P} X \Rightarrow X_n^2 \xrightarrow{P} X^2;$

7. $X_n \xrightarrow{P} a, Y_n \xrightarrow{P} b, a, b \text{ 为常数} \Rightarrow X_n Y_n \xrightarrow{P} ab;$

8. $X_n \xrightarrow{P} 1 \Rightarrow X_n^{-1} \xrightarrow{P} 1;$

9. $X_n \xrightarrow{P} a, Y_n \xrightarrow{P} b, a, b \neq 0 \text{ 为常数} \Rightarrow X_n Y_n^{-1} \xrightarrow{P} ab^{-1};$

10. $X_n \xrightarrow{P} X, Y \text{ 为随机变量} \Rightarrow X_n Y \xrightarrow{P} XY;$

11. $X_n \xrightarrow{P} X, Y_n \xrightarrow{P} Y \Rightarrow X_n Y_n \xrightarrow{P} XY;$

12. $X_n \xrightarrow{P} X, g(x) \text{ 为 } \mathbb{R} \text{ 上的连续函数} \Rightarrow g(X_n) \xrightarrow{P} g(X).$

定理（Chebyshev不等式）： 设 X 为随机变量， $EX = \mu, DX = \sigma^2$, 则对 $\forall \varepsilon > 0$, 有 $P\{|X - \mu| \geq \varepsilon\} \leq \frac{\sigma^2}{\varepsilon^2}$ 或者 $P\{|X - \mu| < \varepsilon\} \geq 1 - \frac{\sigma^2}{\varepsilon^2}$

单边Chebyshev不等式：

随机变量 X ， $EX = 0, DX = \sigma^2 < \infty$, 则对 $\forall \varepsilon > 0$, 有 $P\{X > \varepsilon\} \leq \frac{\sigma^2}{\sigma^2 + \varepsilon^2}$

应用：利用Chebyshev不等式估计概率的界

定理1（**Chebyshev大数定律**）：设 $X_1, X_2, \dots, X_n, \dots$ 独立同分布， EX_1 和 DX_1 存在， $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ ，则对 $\forall \varepsilon > 0$ ，有 $\lim_{n \rightarrow \infty} P\{|\bar{X}_n - E\bar{X}_n| \geq \varepsilon\} = 0$
若 $X_1, X_2, \dots, X_n, \dots$ 两两不相关，且存在常数 C 使得 $DX_i \leq C, i = 1, 2, \dots$ ，结论仍成立。

定理2（**马尔可夫大数定律**）：若 $\{X_n\}$ 满足 $\frac{1}{n^2} D \sum_{i=1}^n X_i \rightarrow 0 (n \rightarrow \infty)$
且 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ ，则对 $\forall \varepsilon > 0$ ，有 $\lim_{n \rightarrow \infty} P\{|\bar{X}_n - E\bar{X}_n| \geq \varepsilon\} = 0$

定理3（**伯努利大数定律**）：设 $f_n(A)$ 是 n 次独立重复试验中事件 A 发生的频率， p 是事件 A 在每次试验中发生的概率，则对 $\forall \varepsilon > 0$ ，有
 $\lim_{n \rightarrow \infty} P\{|f_n(A) - p| < \varepsilon\} = 1$ 或者 $\lim_{n \rightarrow \infty} P\{|f_n(A) - p| \geq \varepsilon\} = 0$

定理4（**辛钦大数定律**）：设 $X_1, X_2, \dots, X_n, \dots$ 独立同分布， $EX_n = \mu$ ，则对 $\forall \varepsilon > 0$ ，有
 $\lim_{n \rightarrow \infty} P\left\{\left|\frac{1}{n} \sum_{i=1}^n X_i - \mu\right| < \varepsilon\right\} = 1$

定理5（**Lindeberg-Levy定理**）（**独立同分布**的中心极限定理）：设 $X_1, X_2, \dots, X_n, \dots$ 独立同分布， $EX_n = \mu, DX_n = \sigma^2$ ，随机变量 $Y_n = \frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n\sigma^2}}$ ，则对 $\forall x$ ， Y_n 的分布

函数 $F_n(x)$ 满足：
$$\lim_{n \rightarrow \infty} F_n(x) = \lim_{n \rightarrow \infty} P\left(\frac{\sum_{i=1}^n X_i - n\mu}{\sqrt{n\sigma^2}} \leq x\right) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$

定理6（**De Moirve-Laplace极限定理**）：若 μ_n 是 n 次独立重复试验（ n 重**伯努利**试验）中事件A发生的次数， $0 < p < 1$ 是事件A在每次试验中发生的概率，则

（积分极限定理）对任意 x ，
$$\lim_{n \rightarrow \infty} P\left(\frac{\mu_n - np}{\sqrt{np(1-p)}} \leq x\right) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt = \Phi(x).$$

定理7（**李雅普诺夫定理**）（**独立不同分布**的中心极限定理）：设 $\{X_i\}$ 独立随机变量序列， $EX_i = \mu_i, DX_i = \sigma_i^2 > 0, B_n^2 = \sum_{i=1}^n \sigma_i^2$ ，随机变量 $Y_n = \frac{\sum_{i=1}^n (X_i - \mu_i)}{B_n}$ ，若存在

$\delta > 0$ 使得 $\frac{1}{B_n^{2+\delta}} \sum_{i=1}^n E|X_i - \mu_i|^{2+\delta} \rightarrow 0, n \rightarrow \infty$ ，则对 $\forall x$ ， Y_n 的分布函数 $F_n(x)$ 满足：

$$\lim_{n \rightarrow \infty} F_n(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$

数理统计

- 六. 数理统计的基本概念
- 七. 参数估计
- 八. 假设检验

第六章 数理统计的基本概念

1. 总体与样本
2. 统计量
3. 抽样分布（ χ^2 分布、t分布、F分布）

总体：研究对象的全体。

个体：总体中的每一个元素。

抽样：从总体中抽取有限个个体对总体进行观察的取值过程。

样本观测值：从一个总体 X 中，随机抽取 n 个个体 $x_1, x_2, \dots, x_n$ ，其中每个 x_i 是一次抽样观测结果，称 $x_1, x_2, \dots, x_n$ 为总体 X 的一组样本观测值。

容量为 n 的样本：每个 x_i 可以看作是某个随机变量 X_i 所取的观测值，称 $(X_1, X_2, \dots, X_n)$ 为容量为 n 的样本。

样本值：样本 $(X_1, X_2, \dots, X_n)$ 的一组观测值 $(x_1, x_2, \dots, x_n)$

样本空间：样本可能取值的全体。

参数：样本分布中的未知常数

参数空间：参数的范围

简单随机样本：**代表性**（样本每个分量与总体分布相同），**独立性**（ X_i 相互独立）

$X_1, X_2, \dots, X_n$ 是总体 X 的一个样本, $T(x_1, x_2, \dots, x_n)$ 是连续函数, 如果这个函数不包含任何未知参数, 称 $T(X_1, X_2, \dots, X_n)$ 是一个统计量。

如果 $(x_1, x_2, \dots, x_n)$ 是一个样本值, 称 $T(x_1, x_2, \dots, x_n)$ 是统计量 $T(X_1, X_2, \dots, X_n)$ 的一个观测值。

每一个统计量都是样本的已知函数, 当总体 X 的分布函数已知时, 统计量的分布是确定的。统计量的分布称为抽样分布。

在统计中, 凡是能由样本计算出来的量就称为统计量。

一个统计量仅与样本本身有关, 与样本分布或者参数无关。

常用的统计量——样本矩：

样本均值： $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$

修正的样本方差： $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} [\sum_{i=1}^n (X_i)^2 - n(\bar{X})^2]$

修正的样本标准差： $S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}$

样本k阶原点矩： $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$

样本k阶中心矩： $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$

未修正的样本方差： $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} [\sum_{i=1}^n (X_i)^2 - n(\bar{X})^2]$

未修正的样本标准差： $S_n = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2}$

样本矩的性质:

- $\sum_{i=1}^n (X_i - \bar{X}) = 0$
- $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} [\sum_{i=1}^n (X_i)^2 - n(\bar{X})^2]$
- $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} [\sum_{i=1}^n (X_i)^2 - n(\bar{X})^2] = \frac{1}{n} \sum_{i=1}^n (X_i)^2 - (\bar{X})^2$
- $\sum_{i=1}^n (X_i - \bar{X})^2 = \min_c \sum_{i=1}^n (X_i - c)^2$, 等号成立当且仅当 $\bar{X} = c$
- $X_1, X_2, \dots, X_n$ 是总体 X 的一个样本, X 的期望和方差存在, $\mu = EX, \sigma^2 = DX$, 则 $E\bar{X} = EX = \mu, D\bar{X} = DX/n = \sigma^2/n$.
- 总体 X 的方差存在, $\mu = EX, \sigma^2 = DX$, 则对样本方差有 $ES^2 = \sigma^2$.
- $X \sim N(\mu, \sigma^2), \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right); T = \sum_{i=1}^n c_i X_i \sim N(\mu \sum_{i=1}^n c_i, \sigma^2 \sum_{i=1}^n c_i)$.

统计中常用的抽样分布（顺序统计量）

若 $(X_1, X_2, \dots, X_n)$ 是总体 X 的一个样本，对任意的样本观测值 $(x_1, x_2, \dots, x_n)$ 重新排序 $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$ ，定义随机变量 $X_{(i)}$ ，对于上述排列，它取值 $x_{(i)}$ 。称 $X_{(i)}$ 为样本 $(X_1, X_2, \dots, X_n)$ 的第 i 个顺序统计量。

$$X_{(1)} = \min(X_1, X_2, \dots, X_n), F_{X_{(1)}}(x) = 1 - [1 - F(x)]^n, f_{X_{(1)}}(x) = n[1 - F(x)]^{n-1}f(x)$$

$$X_{(n)} = \max(X_1, X_2, \dots, X_n), F_{X_{(n)}}(x) = [F(x)]^n, f_{X_{(n)}}(x) = n[F(x)]^{n-1}f(x)$$

$$X_{(k)}: F_k(x) = P\{X_{(k)} \leq x\} = \sum_{m=k}^n C_n^m F^m(x) [1 - F(x)]^{n-m} = k C_n^k \int_0^{F(x)} t^{k-1} (1-t)^{n-k} dt$$
$$f_k(x) = k C_n^k F^{k-1}(x) [1 - F(x)]^{n-k} f(x)$$

极差: $R = X_{(n)} - X_{(1)}$

统计中常用的抽样分布（总体为正态时）

(1) χ^2 分布: $\chi^2 = \sum_{i=1}^n X_i^2 \sim \chi^2(n)$ 其中 $X_1, X_2, \dots, X_n$ 是总体 $N(0,1)$ 的样本

(2) t分布: $T = \frac{X}{\sqrt{Y/N}} \sim t(n)$ 其中 $X \sim N(0,1), Y \sim \chi^2(n)$, X 和 Y 相互独立

(3) F分布: $F = \frac{X/n_1}{Y/n_2} \sim F(n_1, n_2)$ 其中 $X \sim \chi^2(n_1), Y \sim \chi^2(n_2)$, X 和 Y 相互独立

α 分位点 $\forall \alpha \in (0,1)$

(1) χ^2 分布: $\chi_\alpha^2(n): P\{\chi^2 > \chi_\alpha^2(n)\} = \alpha$

当 n 充分大, $\chi_\alpha^2(n) \approx \frac{1}{2}(u_\alpha + \sqrt{2n-1})^2$, $\Phi(u_\alpha) = 1 - \alpha$

(2) t分布: $t_\alpha(n): P\{t > t_\alpha(n)\} = \alpha$

(3) F分布: $F_\alpha(n_1, n_2): P\{F > F_\alpha(n_1, n_2)\} = \alpha$

概率密度函数中，只有自由度，没有未知参数。

$$(1) \chi^2 \text{分布与} \Gamma(\frac{n}{2}, \frac{1}{2}) \text{有相同: } f(x) = \begin{cases} 0, & x \leq 0 \\ \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} x^{\frac{n}{2}-1} e^{-\frac{x}{2}}, & x > 0 \end{cases}$$

$$(2) \text{t分布: } f(x) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi} \Gamma(\frac{n}{2})} (1 + \frac{x^2}{n})^{-\frac{n+1}{2}}, -\infty < x < +\infty$$

$$(3) \text{F分布: } f(x) = \begin{cases} 0, & x \leq 0 \\ \frac{\Gamma(\frac{n_1+n_2}{2}) (\frac{n_1}{n_2})^{\frac{n_1}{2}} x^{\frac{n_1}{2}-1}}{\Gamma(\frac{n_1}{2}) \Gamma(\frac{n_2}{2}) (1+\frac{n_1}{n_2}x)^{\frac{n_1+n_2}{2}}}, & x > 0 \end{cases}$$

(1) χ^2 分布的一些结论:

- 随着 n 增大, 对称性越来越好, 峰度越来越小; 图形越来越接近正态分布的概率密度函数; 图形越来越向右移动, 尾部越来越大.
- 若 $\chi^2 \sim \chi^2(n)$, $E\chi^2 = n$, $D\chi^2 = 2n$.
- $n \rightarrow \infty$, 自由度为 n 的 χ^2 收敛于正态分布.
- 若 $\chi_1^2 \sim \chi^2(n_1)$, $\chi_2^2 \sim \chi^2(n_2)$, 且 χ_1^2 与 χ_2^2 相互独立, 则 $\chi_1^2 + \chi_2^2 \sim \chi^2(n_1 + n_2)$.
- 若 $\chi_i^2 \sim \chi^2(n_i)$, $i = 1, 2, \dots, m$, 且相互独立, 则 $\sum_{i=1}^m \chi_i^2 \sim \chi^2(\sum_{i=1}^m n_i)$.
- $X_1, X_2, \dots, X_n$ 是总体 $X \sim N(\mu, \sigma^2)$ 的样本, $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right)$;
 $\frac{\xi}{\sigma^2} = \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma}\right)^2 \sim \chi^2(n)$; $\frac{n-1}{\sigma^2} S^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 \sim \chi^2(n-1)$; $\bar{X}$ 与 S^2 相互独立.

(2) t分布的一些结论:

- $X \sim N(\mu, \sigma^2), Y/\sigma^2 \sim \chi^2(n)$, X 和 Y 相互独立, 则 $T = \frac{X-\mu}{\sqrt{Y/N}} \sim t(n)$.
- $f(x)$ 关于 y 轴对称, 是偶函数, 即 $f(-x) = f(x)$, 故 $t_{1-\alpha}(n) = -t_{\alpha}(n)$
- 随着 n 增大, 峰度越来越高, 尾部越来越小, $\lim_{|x| \rightarrow \infty} f(x) = 0$.
- 对于固定的 x , 有 $\lim_{n \rightarrow \infty} \left(1 + \frac{x^2}{n}\right)^{-(n+1)/2} = e^{-x^2/2}$

当 n 充分大, 近似地有 $T \sim N(0,1)$, $t_{\alpha}(n) = u_{\alpha}$

- $n = 1$ 时, 是Cauchy分布, 期望不存在。
- 若 $T \sim t(n), n > 2$, 则 $ET = 0, DT = n/(n-2)$.
- $X_1, X_2, \dots, X_n$ 是正态总体 $N(\mu, \sigma^2)$ 的样本, 则 $T = \frac{\sqrt{n}(\bar{X}-\mu)}{S} \sim t(n-1)$.

(3) F分布的一些结论:

- $n_1 \rightarrow \infty$, 统计量 $n_1 F(n_1, n_2)$ 依概率收敛于一个自由度为 n_1 的 χ^2 随机变量;
 $n_2 \rightarrow \infty$, 统计量 $n_2 F(n_1, n_2)$ 依概率收敛于一个自由度为 n_2 的 χ^2 随机变量;
 - 若 $F \sim F(n_1, n_2)$, 则 $\frac{1}{F} \sim F(n_2, n_1)$.
 - $F_\alpha(n_1, n_2) = \frac{1}{F_{1-\alpha}(n_2, n_1)}$
 - $F(1, n) = (t(n))^2$.
 - 若 $X \sim \chi^2(n_1), Y \sim \chi^2(n_2)$, X 和 Y 相互独立, 则 $\xi = X + Y$ 和 $\eta = X/Y$ 相互独立。
 - $X_1, X_2, \dots, X_{n_1}$ 是正态总体 $X \sim N(\mu_1, \sigma_1^2)$ 的样本, $Y_1, Y_2, \dots, Y_{n_2}$ 是正态总体 $Y \sim N(\mu_2, \sigma_2^2)$ 的样本, 两个样本相互独立, 样本均值和方差分别为 $\bar{X} = \frac{1}{n_1} \sum_{i=1}^{n_1} X_i, \bar{Y} = \frac{1}{n_2} \sum_{i=1}^{n_2} Y_i, S_{n_1}^2 = \frac{1}{n_1-1} \sum_{i=1}^{n_1} (X_i - \bar{X})^2, S_{n_2}^2 = \frac{1}{n_2-1} \sum_{i=1}^{n_2} (Y_i - \bar{Y})^2$, 则 $F = \frac{S_{n_1}^2/\sigma_1^2}{S_{n_2}^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1)$.
- 若 $\sigma_1^2 = \sigma_2^2 = \sigma^2$, 则 $F = \frac{S_{n_1}^2}{S_{n_2}^2} \sim F(n_1 - 1, n_2 - 1), T = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\frac{(n_1-1)S_{n_1}^2 + (n_2-1)S_{n_2}^2}{n_1+n_2-2}} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$

第七章 参数估计

1. 点估计的概念与评价标准（无偏、有效、一致）
2. 参数的点估计（矩估计、极大似然估计）
3. 区间估计（单正态总体的区间估计）

假设总体 X 有一族可能的分布 F ， F 的函数形式已知，仅含有未知参数，记 θ 是支配分布的未知参数（可以是向量），称 θ 的全部可容许值组成的集合为参数空间，记为 Θ 。

总体 X 具有分布族 $\{F(x, \theta), \theta \in \Theta\}$ ， $X_1, X_2, \dots, X_n$ 是总体 X 的一个子样。点估计问题：要求构造一个统计量 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 作为参数 θ 的估计（维数相同）。称 $\hat{\theta}$ 为 θ 的估计量。

如果 $x_1, x_2, \dots, x_n$ 是子样的一组观测值，代入统计量 $\hat{\theta}(X_1, X_2, \dots, X_n)$ 中就得到具体值 $\hat{\theta}(x_1, x_2, \dots, x_n)$ ，这个值称为 θ 的估计值。

估计量和估计值统称为估计。

样本矩：

$$\text{样本均值: } \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\text{样本方差: } S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n-1} [\sum_{i=1}^n (X_i)^2 - n(\bar{X})^2]$$

$$\text{样本k阶原点矩: } A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$$

$$\text{样本k阶中心矩: } B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$$

总体矩：

$$\text{总体均值: } \mu = EX$$

$$\text{总体方差: } \sigma^2 = DX$$

$$\text{总体k阶原点矩: } \alpha_k = EX^k$$

$$\text{总体k阶中心矩: } \mu_k = E(X - \mu)^k$$

矩估计:

总体 X 的分布函数为 $F(x, \theta)$, $\theta = (\theta_1, \theta_2, \dots, \theta_k)$ 是未知参数向量, 假设总体的 k 阶矩 $\alpha_k = EX^k$ 存在, 则 $\alpha_k = \alpha_k(\theta_1, \theta_2, \dots, \theta_k)$ 为 θ 的函数。

用样本矩作为相应总体矩的估计, 即

$$\alpha_l(\theta_1, \theta_2, \dots, \theta_k) = A_l = \frac{1}{n} \sum_{i=1}^n X_i^l, \quad l = 1, 2, \dots, k$$

确定了包含 k 个未知参数的 k 个方程, 解此方程组可得到 $\theta = (\theta_1, \theta_2, \dots, \theta_k)$ 的一组解 $\hat{\theta} = (\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k)$ 。

样本矩 A_l 是随机变量, 故 $\hat{\theta} = (\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k)$ 也是随机变量。

将 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ 作为 $\theta_1, \theta_2, \dots, \theta_k$ 的估计, 称为矩估计。

这种求估计量的方法称为矩方法。

$X_1, X_2, \dots, X_n$ 是总体 X 的一个样本, $x_1, x_2, \dots, x_n$ 是一组样本观测值。

定义（**似然函数**）：如果以 $f(x, \theta)$ 记 n 个样本的联合概率分布, 则对于给定的样本观测值 $x = (x_1, x_2, \dots, x_n)$, 称 $f(x, \theta)$ 为参数 θ 的似然函数, 记为 $L(\theta, x) = f(x, \theta), \theta \in \Theta$. 称 $\ln L(\theta, x)$ 为对数似然函数。

定义（**MLE**）： $X_1, X_2, \dots, X_n$ 是来自某概率分布 $f(x, \theta), \theta \in \Theta$ 的一个样本, 如果统计量 $\hat{\theta}(x_1, x_2, \dots, x_n)$ 满足

似然函数 $L(\hat{\theta}, x_1, x_2, \dots, x_n) = \max_{\theta \in \Theta} L(\theta, x_1, x_2, \dots, x_n) \triangleq \prod_{i=1}^n f(x_i, \theta), \theta \in \Theta$

或者等价地满足**对数似然函数** $\ln L(\hat{\theta}, x_1, x_2, \dots, x_n) = \max_{\theta \in \Theta} \ln L(\theta, x_1, x_2, \dots, x_n),$

称 $\hat{\theta}$ 为 θ 的**极大似然估计**。

似然方程:

$$\frac{\partial L(\theta, x_1, x_2, \dots, x_n)}{\partial \theta_i} \Big|_{\theta=\hat{\theta}} = 0, i = 1, 2, \dots, k$$
$$\frac{\partial \ln L(\theta, x_1, x_2, \dots, x_n)}{\partial \theta_i} \Big|_{\theta=\hat{\theta}} = 0, i = 1, 2, \dots, k$$

矩估计的说明：

- 也可以通过样本的 k 阶中心距作为总体 k 阶中心距的估计，建立相应的方程组，这样求得的参数估计也称为矩估计。这两种方法得到的估计可能不相同。
- 方程组的解是否存在且唯一，要取决于具体问题。
- 在用矩方法求参数估计时，尽可能用低阶矩。

似然估计的说明：

- 似然函数和样本的联合概率分布是同一个东西，但二者含义不同：
联合分布是固定参数值为 θ 下的关于样本 x 的函数，取值空间是样本空间；
似然函数是固定样本值下关于参数 θ 的函数，取值空间为参数空间。
给定参数后，样本联合分布告诉我们哪个样本将以多大概率被观测到；
反过来，有了样本以后，似然函数告诉我们如何最有可能的取参数的估计。
- 不变原则：如果 $g(\theta)$ 是一一映射，且 $\hat{\theta}$ 是 θ 的MLE，则 $g(\hat{\theta})$ 也是 $g(\theta)$ 的MLE。

1. 无偏性 (估计值的期望等于参数真值)
2. 有效性 (方差最小——除无系统偏差外, 要求估计精度更高)
3. 一致性 (依概率收敛——随 n 增大, 估计量的值稳定于参数真值)

无偏估计量: $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是未知参数 θ 的估计量, 并且对 $\forall \theta \in \Theta$, $E_{\theta}(\hat{\theta}) = \theta$ 称 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是 θ 的无偏估计量。

设 $\hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_n)$ 和 $\hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_n)$ 都是 θ 的无偏估计, 如果 $D\hat{\theta}_1 \leq D\hat{\theta}_2$, 称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效。

θ 的所有无偏估计量, 如果存在一个无偏估计量 $\hat{\theta}_0 = \hat{\theta}_0(X_1, X_2, \dots, X_n)$, 它的方差最小, 称 $\hat{\theta}_0$ 是 θ 的最小方差无偏估计。

~~$\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是未知参数 θ 的估计量, 对 $\forall \theta \in \Theta$, 当 $n \rightarrow \infty$ 时, $\hat{\theta}$ 依概率收敛于 θ , 即 $\lim_{n \rightarrow \infty} P\{|\hat{\theta} - \theta| < \varepsilon\} = 1$.~~

称 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是 θ 的一致估计量, 记为 $\hat{\theta} \xrightarrow{P} \theta (n \rightarrow \infty)$.

若总体 X 的 k 阶原点矩 EX^k 存在且有限, 则样本 k 阶原点矩 A_k 是其一致无偏估计。

总体 X 的均值 μ 的估计: $\hat{\mu} = \bar{X}$

是矩估计, 无偏估计, 所有线性无偏估计中方差最小的。

总体 X 的方差 σ^2 的估计

样本2阶中心矩 $B_2 = \frac{n-1}{n} S^2$, 是矩估计, 一致估计, 有偏;

样本方差 S^2 是 σ^2 的一致无偏估计。

正态分布未知参数 μ 和 σ^2 的估计

矩估计与极大似然估计一样: $\hat{\mu} = \bar{X}$, $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = B_2$

σ^2 的一致最小方差无偏估计: $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$

样本标准差 S 不是总体标准差 σ 的无偏估计, $ES = \sigma \sqrt{\frac{2}{n-1}} \frac{\Gamma(\frac{n}{2})}{\Gamma(\frac{n-1}{2})}$

$$D[\frac{n-1}{\sigma^2} S^2] = \frac{(n-1)^2}{\sigma^4} DS^2 = 2(n-1), \quad DS^2 = \frac{2\sigma^4}{n-1}$$

均匀分布的未知参数的估计

- 总体 $X \sim U(a, b)$, 未知参数 a, b 的矩估计:

$$\hat{a} = A_1 - \sqrt{3(A_2 - A_1^2)}, \quad \hat{b} = A_1 + \sqrt{3(A_2 - A_1^2)}$$

- 总体 $X \sim U(0, \theta)$ 的未知参数 θ 的估计

矩估计: $\hat{\theta}_M = 2\bar{X}$, $E\hat{\theta}_M = \theta$ (无偏), $D\hat{\theta}_M = \frac{\theta^2}{3n}$

极大似然估计: $\hat{\theta}_L = X_{(n)}$, $E\hat{\theta}_L = \frac{n}{n+1}\theta$ (有偏), $D\hat{\theta}_L = \frac{n\theta^2}{(n+2)(n+1)^2}$

$$\hat{\theta} = \frac{n+1}{n}X_{(n)} \text{ (一致最小方差无偏估计)}, \quad D\hat{\theta} = \frac{(n+1)^2}{n^2}D\hat{\theta}_L = \frac{\theta^2}{n(n+2)}$$

- 总体 $X \sim U(\theta, \theta + 1)$, 未知参数 θ 的极大似然估计不唯一, $\hat{\theta} \in [X_{(n)} - 1, X_{(1)}]$.

Possion分布 $P(\lambda)$ 的未知参数 λ 的估计

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, k = 0, 1, 2, \dots, \lambda > 0$$

λ 的矩估计: $\hat{\lambda} = \bar{X}, \hat{\lambda} = B_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$

λ 的极大似然估计: $\hat{\lambda} = \bar{X}$

$\alpha \bar{X} + (1 - \alpha) S^2, (0 \leq \alpha \leq 1)$ 是 λ 的无偏估计

总体 $X \sim \Gamma(\alpha, \beta)$, 未知参数 α, β 的矩估计: $\hat{\alpha} = \bar{X}^2 / B_2, \hat{\beta} = \bar{X} / B_2$

分布	概率分布	期望	方差	矩估计
两点分布 $B(1, p)$	$P(X = k) = p^k(1 - p)^{1-k}, \quad k = 0, 1$	p	$p - p^2$	$\hat{p} = \bar{X}$ （极大似然）
二项分布 $B(n, p)$	$P(X = k) = C_n^k p^k(1 - p)^{n-k}, \quad k = 0, 1, 2, \dots, n$	np	$np(1 - p)$	n 已知: $\hat{p} = \bar{X}/n$ （极大似然） n 未知: $\hat{p} = (\bar{X} - B_2)/\bar{X}, \hat{n} = \bar{X}^2/(\bar{X} - B_2)$
几何分布 $G(p)$	$P(X = k) = (1 - p)^{k-1}p, \quad k = 1, 2, \dots,$	$\frac{1}{p}$	$\frac{1 - p}{p^2}$	$\hat{p} = \frac{1}{\bar{X}}$ （极大似然）
泊松分布 $P(\lambda)$ $\lambda > 0$	$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k = 0, 1, 2, \dots$	λ	λ	$\hat{\lambda} = \bar{X}$ （极大似然） $\hat{\lambda} = B_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$
均匀分布 $U(a, b)$ $a < b$	$f(x) = \begin{cases} \frac{1}{b-a}, & x \in (a, b) \\ 0, & x \notin (a, b) \end{cases}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	$\hat{a} = A_1 - \sqrt{3(A_2 - A_1^2)},$ $\hat{b} = A_1 + \sqrt{3(A_2 - A_1^2)}$
指数分布 $E(\lambda)$ $\lambda > 0$	$f(x) = \begin{cases} 0, & x < 0 \\ \lambda e^{-\lambda x}, & x \geq 0 \end{cases}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$	$\hat{\lambda} = \frac{1}{\bar{X}}$ （极大似然）
Γ 分布 $\Gamma(\alpha, \beta)$ $\alpha, \beta > 0$	$f(x) = \begin{cases} 0, & x \leq 0 \\ \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, & x > 0 \end{cases}$	$\frac{\alpha}{\beta}$	$\frac{\alpha}{\beta^2}$	$\hat{\alpha} = \bar{X}^2/B_2, \quad \hat{\beta} = \bar{X}/B_2$
正态分布 $N(\mu, \sigma^2)$	$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, x \in (-\infty, +\infty)$	μ	σ^2	$\hat{\mu} = \bar{X}$ （极大似然） $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = B_2$ （极大似然）

设总体 X 的分布函数为 $F(x, \theta)$, θ 为未知参数, $X_1, X_2, \dots, X_n$ 为 X 的样本, 如果 $\hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_n)$ 和 $\hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_n)$ 是两个统计量, 且 $\hat{\theta}_1 \leq \hat{\theta}_2$, 则称区间 $(\hat{\theta}_1, \hat{\theta}_2)$ 为参数 θ 的一个区间估计。

当参数的真值为 θ 时, 区间 $(\hat{\theta}_1, \hat{\theta}_2)$ 包含 θ 的概率 $P(\hat{\theta}_1 < \theta < \hat{\theta}_2)$ 越大越好, 这个概率就称为置信度 (置信水平)。这个置信度依赖于参数真值。

设区间 $(\hat{\theta}_1, \hat{\theta}_2)$ 为参数 θ 的一个区间估计, 称 $\inf_{\theta \in \Theta} P(\hat{\theta}_1 < \theta < \hat{\theta}_2)$ 为该区间估计的置信系数。

如果置信度不依赖于未知参数, 则置信系数就是置信度。


设总体 X 的分布函数为 $F(x, \theta)$, θ 为未知参数, $X_1, X_2, \dots, X_n$ 为 X 的样本, 给定 $0 < \alpha < 1$, 若统计量 $\hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_n)$ 和 $\hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_n)$ 满足 $P(\hat{\theta}_1 < \theta < \hat{\theta}_2) = 1 - \alpha$, 则称 $(\hat{\theta}_1, \hat{\theta}_2)$ 为参数 θ 的置信度为 $1 - \alpha$ 的置信区间, $\hat{\theta}_1, \hat{\theta}_2$ 称为置信下限和置信上限, $1 - \alpha$ 为置信度 (置信水平)。

单正态总体 $N(\mu, \sigma^2)$

代估参量	条件	统计量	置信度为 $1 - \alpha$ 的置信区间
均值 μ	σ^2 已知	$U = \sqrt{n} \frac{\bar{X} - \mu}{\sigma} \sim N(0,1)$	$(\bar{X} - \frac{\sigma}{\sqrt{n}} u_{\frac{\alpha}{2}}, \bar{X} + \frac{\sigma}{\sqrt{n}} u_{\frac{\alpha}{2}})$
	σ^2 未知	$T = \frac{\sqrt{n}(\bar{X} - \mu)}{S} \sim t(n-1)$	$(\bar{X} - \frac{S}{\sqrt{n}} t_{\frac{\alpha}{2}}(n-1), \bar{X} + \frac{S}{\sqrt{n}} t_{\frac{\alpha}{2}}(n-1))$
方差 σ^2	μ 已知	$\chi^2 = \frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} \sim \chi^2(n)$	$(\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{\frac{\alpha}{2}}^2(n)}, \frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{1-\frac{\alpha}{2}}^2(n)})$
	μ 未知	$\chi^2 = \frac{n-1}{\sigma^2} S^2 \sim \chi^2(n-1)$	$(\frac{(n-1)S^2}{\chi_{\frac{\alpha}{2}}^2(n-1)}, \frac{(n-1)S^2}{\chi_{1-\frac{\alpha}{2}}^2(n-1)})$

第八章 假设检验

1. 假设检验的基本概念和方法
2. 正态总体均值的假设检验（单正态总体均值的双边检验）
3. 正态总体方差的假设检验（单正态总体方差的双边检验）



在总体的未知分布上所作的假设称为统计假设，记为 H_0 。

提出的假设 H_0 被称为原（零）假设，
与之相反的假设称为对立（备选）假设，记为 H_1 。

选择原假设的原则： H_0 是希望被接受的假设。

假设检验的基本思想——实际推断原理：小概率事件在一次试验中几乎不可能发生。

当 H_0 是简单假设（参数只有一个点），其形式可以写成 $H_0: \theta = \theta_0$ ，此时的备选假设有两种可能：

$$H_1': \theta \neq \theta_0 \text{（双边的）}$$

$$\cancel{H_1'': \theta < \theta_0 \text{ 或 } \theta > \theta_0 \text{（单边的）}}$$

检验就等价于把样本空间划分成两个互不相交的部分 W 和 $\bar{W}$ ，
当样本属于接受域 $\bar{W}$ 时，接受 H_0 ；
当样本属于拒绝域 W 时，拒绝 H_0 。

检验法的错误分类：

- 弃真错误—— H_0 成立但被拒绝
- 取伪错误—— H_0 不成立但被接受

$$P\{\text{拒绝}H_0|H_0\text{为真}\} = \alpha$$

$$P\{\text{接受}H_0|H_0\text{不真}\} = \beta$$

只对第一类错误，弃真错误的概率加以控制的检验问题，称为显著性假设检验问题。

假设检验的一般步骤：

- 根据实际问题提出原假设 H_0 和对立假设 H_1 ；
- 在给定显著性水平 α 后，抽取容量为 n 的样本，构造合适的统计量，在 H_0 为真下导出统计量的分布；
- 确定拒绝域：
依直观分析确定拒绝域的形式，由 $P\{\text{拒绝}H_0|H_0\text{为真}\} = \alpha$ 确定拒绝域；
- 得出结论：根据样本观测值计算统计量的值，若统计量的值落入拒绝域，则拒绝 H_0 ，否则接受 H_0 。

单正态总体 $N(\mu, \sigma^2)$ 的参数在显著性水平 α 下的双边检验

待检验参量	条件	H_0	H_1	统计量	拒绝域 W
均值 μ	σ^2 已知 $\sigma^2 = \sigma_0^2$	$\mu = \mu_0$	$\mu \neq \mu_0$	$U = \sqrt{n} \frac{\bar{X} - \mu_0}{\sigma_0}$	$ U > u_{\alpha/2}$
	σ^2 未知	$\mu = \mu_0$	$\mu \neq \mu_0$	$T = \frac{\sqrt{n}(\bar{X} - \mu_0)}{S}$	$ T > t_{\frac{\alpha}{2}}(n - 1)$
方差 σ^2	μ 已知 $\mu = \mu_0$	$\sigma^2 = \sigma_0^2$	$\sigma^2 \neq \sigma_0^2$	$\chi^2 = \frac{\sum_{i=1}^n (X_i - \mu_0)^2}{\sigma_0^2}$	$\chi^2 > \chi_{\frac{\alpha}{2}}^2(n)$ 或 $\chi^2 < \chi_{1-\alpha/2}^2(n)$
	μ 未知	$\sigma^2 = \sigma_0^2$	$\sigma^2 \neq \sigma_0^2$	$\chi^2 = \frac{n-1}{\sigma_0^2} S^2$	$\chi^2 > \chi_{\frac{\alpha}{2}}^2(n - 1)$ 或 $\chi^2 < \chi_{1-\frac{\alpha}{2}}^2(n - 1)$